

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



BÁO CÁO DỰ ÁN CÔNG NGHỆ

Ngành: Khoa học máy tính

**PIPELINE NÂNG CAO HIỆU QUẢ CHO
HỆ THỐNG PHÂN LOẠI VĂN BẢN ĐA NHÃN
KHÔNG GIÁM SÁT**

Người thực hiện	: Nguyễn Quang Tuấn
Mã sinh viên	: 22028209
Lớp	: K67I - CS4
Giảng viên hướng dẫn	: TS. Lê Khánh Trình

HÀ NỘI - 2023

Hà Nội, tháng 12 năm 2025

LỜI CẢM ƠN

Lời đầu tiên, em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến các thầy cô trong Khoa Công nghệ thông tin, Bộ môn Công nghệ Phần mềm đã tạo điều kiện thuận lợi, cung cấp môi trường làm việc chuyên nghiệp và hỗ trợ em nhiệt tình trong suốt quá trình thực hiện.

Đặc biệt, em xin bày tỏ lòng biết ơn sâu sắc tới thầy Lê Khánh Trình đã trực tiếp hướng dẫn, chỉ bảo tận tình và truyền đạt cho em nhiều kiến thức, kinh nghiệm quý báu về lĩnh vực an ninh mạng, an toàn phần mềm. Sự giúp đỡ của thầy là nền tảng quan trọng để em có thể hoàn thành tốt báo cáo này

Mặc dù đã rất cố gắng, nhưng do kiến thức và kinh nghiệm còn hạn chế, báo cáo của em khó tránh khỏi những thiếu sót. Em rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy để báo cáo được hoàn thiện hơn.

Em xin chân thành cảm ơn!

Sinh viên,

Nguyễn Quang Tuấn

MỤC LỤC

LỜI CẢM ƠN.....	2
DANH MỤC HÌNH ẢNH.....	4
DANH MỤC BẢNG BIỂU.....	6
CHƯƠNG 1: ĐẶT VẤN ĐỀ.....	7
1.1. Giới thiệu bài toán.....	7
1.1.1. Bối cảnh nghiên cứu.....	7
1.1.2. Định nghĩa bài toán.....	7
1.1.3. Thách thức kỹ thuật.....	8
1.1.4. Ý nghĩa thực tiễn.....	9
1.2. Đóng góp của dự án.....	9
CHƯƠNG 2: KIẾN THỨC CƠ SỞ.....	11
2.1. Mô hình hóa chủ đề.....	11
2.2. Phân loại văn bản đa nhãn.....	12
2.3. Phân loại văn bản Zero-shot.....	12
2.4. Mô hình ngôn ngữ lớn và Embedding.....	13
CHƯƠNG 3: PHƯƠNG PHÁP CỦA SẢN PHẨM.....	14
3.1. Hướng tiếp cận.....	14
3.1.1. Các quan sát nền tảng.....	14
3.1.2. Ý tưởng thiết kế.....	18
3.2. Cách thực hiện.....	19
3.2.1. Tiền xử lý và phân nhóm.....	19
3.2.2. Tạo label space thô ban đầu.....	21
3.2.3. Vòng lặp để mở rộng label space, tăng độ phủ của label space.....	24
3.3. Tổng kết phương pháp.....	29
CHƯƠNG 4: THỰC NGHIỆM VÀ ĐÁNH GIÁ.....	31
4.1. Mục tiêu thực nghiệm.....	31
4.2. Quy trình thực nghiệm.....	31
4.2.1. Thông số đánh giá.....	31
4.2.2. Chi tiết thực nghiệm.....	33
4.2.3. Kết quả độ phủ không gian nhãn.....	35
4.2.4. Kết quả phân loại Zero-shot.....	37
4.2.5. Cải thiện Coverage qua các vòng lặp.....	38
4.2.6. Vấn đề với Amazon-531.....	38
4.2.7. Ảnh hưởng của kích thước chunk.....	39

4.3. Kết luận và Hướng phát triển.....	40
4.3.1. Kết luận.....	40
4.3.2. Hạn chế.....	40
4.3.3. Hướng phát triển.....	41
TÀI LIỆU THAM KHẢO.....	42

DANH MỤC HÌNH ẢNH

Hình 3.1: Tỷ lệ văn bản có lớp chủ đạo trên các tập dữ liệu.....	16
Hình 3.2: Tỷ lệ các phân phối nhãn đuôi của bộ dữ liệu AAPD.....	17
Hình 3.3: Tỷ lệ các phân phối nhãn đuôi của bộ dữ liệu RCV1-v2.....	17
Hình 3.4: Quy trình Phase 1 + Phase 2 của pipeline.....	19
Hình 3.5: Quy trình Phase 3 + Phase 4 của pipeline.....	22
Hình 3.6: Quy trình Phase 5 của pipeline.....	24
Hình 3.7: Quy trình Phase 6 của pipeline.....	27
Hình 4.1: So sánh độ chính xác phân loại với 3 mô hình entailment.....	37
Hình 4.2: Cải thiện Coverage qua việc tăng số lần lặp lại trên Amazon-531.....	39

DANH MỤC BẢNG BIỂU

Bảng 3.1: Tỷ lệ văn bản có lớp chủ đạo trên các tập dữ liệu.....	14
Bảng 3.2: Tóm tắt ba giai đoạn của MiniML.....	28
Bảng 4.1: Thống kê chi tiết các tập dữ liệu benchmark.....	32
Bảng 4.2: Chi tiết triển khai hệ thống.....	34
Bảng 4.3: So sánh độ phủ không gian nhãn (%) - Giá trị cao nhất được in đậm.....	34
Bảng 4.4: So sánh độ chính xác phân loại Zero-shot Multi-label.....	36
Bảng 4.5: Cải thiện Coverage qua quy trình cải thiện lặp lại.....	37

CHƯƠNG 1: ĐẶT VẤN ĐỀ

1.1. Giới thiệu bài toán

1.1.1. Bối cảnh nghiên cứu

Trong kỷ nguyên số hóa, khối lượng văn bản tăng trưởng nhanh chóng, đòi hỏi các hệ thống tự động phân loại và tổ chức thông tin hiệu quả. Phân loại văn bản đa nhãn cho phép gán nhiều danh mục cho một văn bản, phản ánh chính xác bản chất đa nghĩa của thông tin thực tế.

Tuy nhiên, các phương pháp truyền thống yêu cầu người dùng cung cấp trước danh sách nhãn đầy đủ, gây khó khăn trong thực tế do số lượng văn bản lớn, chủ đề đa dạng và liên tục thay đổi, đồng thời thiếu chuyên gia định nghĩa không gian nhãn. Các lĩnh vực như thương mại điện tử, tin tức, quản lý tài liệu doanh nghiệp và nghiên cứu khoa học đặc biệt gặp thách thức này.

1.1.2. Định nghĩa bài toán

Dự án này tập trung vào một vấn đề mới và đầy thách thức trong lĩnh vực xử lý ngôn ngữ tự nhiên: Phân loại văn bản đa nhãn thể giới mở với giám sát yếu cực độ (Extremely Weak Supervision - XWS) [\[1\]](#). Trong thiết lập XWS, người dùng chỉ cung cấp:

- Một mô tả ngắn gọn về mục tiêu phân loại (classification objective)
- Không có bất kỳ nhãn cụ thể nào được cung cấp trước

- Không có thông tin về không gian nhãn thực tế (ground-truth label space)
- Không có dữ liệu huấn luyện đã được gán nhãn

Định nghĩa "thế giới mở" (open-world) trong dự án này biểu thị sự vắng mặt hoàn toàn của bất kỳ thông tin lớp nào trong cả giai đoạn huấn luyện và kiểm thử. Điều này nghiêm ngặt hơn so với định nghĩa truyền thống, nơi các nhãn mới chỉ xuất hiện trong giai đoạn kiểm thử. [\[2\]](#)

Về mặt hình thức toán học, bài toán được định nghĩa như sau:

Cho tập văn bản không có nhãn $D = \{D_1, D_2, \dots, D_K\}$, trong đó $D_i \in D$ đại diện cho một văn bản trong tập dữ liệu. Nhiệm vụ bao gồm hai phần:

1. Xác định tên các lớp $C = \{C_k\}_{k=1}^K$, với K là số lượng lớp chưa biết trước
2. Xây dựng bộ phân loại văn bản $f(\cdot)$ để ánh xạ bất kỳ văn bản thô D_i đến tập các nhãn mục tiêu $Y_i = \{y_{ij}\}_{j=1}^p$, trong đó y_{ij} là tên nhãn đơn lẻ và p là số lượng nhãn mục tiêu cho D_i

1.1.3. Thách thức kỹ thuật

Bài toán đặt ra bốn thách thức chính. Thứ nhất là khám phá không gian nhãn từ văn bản không có nhãn, đòi hỏi hiểu ngữ nghĩa sâu và khái quát hóa thành danh mục phù hợp. Thứ hai là xử lý nhãn hiếm trong phân phối đuôi dài, khi đa số nhãn chỉ xuất hiện ở ít trường hợp nhưng mang thông tin quan trọng. Thứ ba là thực hiện phân loại đa nhãn không giám sát, phức tạp hơn đáng kể so với phân

loại đơn nhãn [3]. Thứ tư là đảm bảo chất lượng nhãn tự động, yêu cầu nhãn có ý nghĩa, không trùng lặp và bao phủ không gian chủ đề.

Các phương pháp hiện có như phân cụm và mô hình hóa chủ đề chỉ gán một nhãn duy nhất cho mỗi văn bản hoặc phải chunking rồi thống kê xử dụng, chưa thích ứng tốt cho bài toán đa nhãn.

1.1.4. Ý nghĩa thực tiễn

Mặc dù bài toán đặt ra nhiều thách thức kỹ thuật, ý nghĩa thực tiễn của nó không thể bị đánh giá thấp. Một hệ thống có khả năng tự động khám phá không gian nhãn và phân loại văn bản đa nhãn sẽ mang lại nhiều lợi ích:

- Giảm đáng kể chi phí và thời gian xây dựng hệ thống phân loại
- Cho phép triển khai trong các lĩnh vực mới
- Tự động thích ứng với các chủ đề mới xuất hiện
- Hỗ trợ các tổ chức không có đội ngũ chuyên gia NLP

1.2. Đóng góp của dự án

Dự án xây dựng MiniML, một pipeline phân loại văn bản đa nhãn trong bối cảnh thế giới mở với giám sát yếu cực độ, không yêu cầu không gian nhãn được định nghĩa trước hay dữ liệu gán nhãn thủ công.

MiniML thực hiện xây dựng không gian nhãn và phân loại theo cách lặp, trong đó không gian nhãn được mở rộng dần dựa trên thông tin ngữ nghĩa từ dữ liệu, đồng thời cập nhật bộ phân loại phù hợp. Cách tiếp cận này giúp xử lý hiệu quả

các nhãn hiếm, vốn thường bị hạn chế trong các phương pháp dựa trên tập nhãn cố định.

Kết quả thực nghiệm trên các tập dữ liệu benchmark cho thấy MiniML đạt độ phủ không gian nhãn vượt trội so với các phương pháp topic modeling và keyword extraction, với 67.36% trên AAPD và 51.12% trên RCV1-V2.

Qua phân tích năm tập dữ liệu benchmark, dự án phát hiện hai đặc điểm quan trọng: hơn 90% văn bản có một lớp chủ đạo bao phủ phần lớn nội dung, và mọi nhãn (kể cả nhãn hiếm) đều xuất hiện như lớp chủ đạo trong ít nhất một văn bản. Những quan sát này là nền tảng cho thiết kế quy trình khám phá và mở rộng không gian nhãn trong MiniML.

CHƯƠNG 2: KIẾN THỨC CƠ SỞ

Chương này trình bày các kiến thức nền tảng cần thiết để hiểu và phát triển hệ thống MiniML, bao gồm mô hình hóa chủ đề, phân loại văn bản đa nhãn, phân loại zero-shot, và các công nghệ hỗ trợ.

2.1. Mô hình hóa chủ đề

Mô hình hóa chủ đề là tập hợp các kỹ thuật thống kê khám phá cấu trúc chủ đề tiềm ẩn trong bộ sưu tập văn bản mà không cần gán nhãn thủ công.

LDA và NMF là hai phương pháp truyền thống phổ biến. LDA biểu diễn văn bản như hỗn hợp các chủ đề sử dụng mô hình xác suất sinh và phân phối Dirichlet, trong khi NMF phân tích ma trận term-document thành tích hai ma trận không âm. Cả hai đều yêu cầu chỉ định trước số lượng chủ đề và chỉ gán một chủ đề chính cho mỗi văn bản.[\[4\]\[5\]](#)

Top2Vec và BERTopic là các phương pháp hiện đại sử dụng embeddings. Top2Vec mở rộng Word2Vec để nhúng chủ đề vào cùng không gian vector với văn bản, sử dụng UMAP giảm chiều và HDBSCAN phân cụm. BERTopic kết hợp BERT embeddings với UMAP, HDBSCAN và c-TF-IDF, tự động xác định số lượng chủ đề và cung cấp biểu diễn ngữ nghĩa chất lượng cao.[\[6\]\[7\]](#)

TopicGPT sử dụng mô hình ngôn ngữ lớn để sinh và gán chủ đề, tạo ra các chủ đề căn chỉnh tốt với nhãn do con người định nghĩa. Tuy nhiên, tất cả các phương pháp trên đều có hạn chế chung là chỉ cung cấp một chủ đề cho mỗi văn bản, khó mở rộng sang kịch bản đa nhãn.[\[8\]](#)

2.2. Phân loại văn bản đa nhãn

Phân loại văn bản đa nhãn gán tập hợp các nhãn phù hợp cho mỗi văn bản, trong đó mỗi văn bản có thể thuộc về bất kỳ tập con nào của K nhãn có thể. Output space là tập lũy thừa 2^K , làm bài toán phức tạp hơn đáng kể so với phân loại đơn nhãn hoặc đa lớp.

Các phương pháp truyền thống bao gồm **SLEEC** sử dụng embedding để biểu diễn văn bản và nhãn trong cùng không gian vector, **XML-CNN** áp dụng mạng nơ-ron tích chập với hàm sigmoid cho mỗi nhãn, và **TaxoClass** thực hiện phân loại phân cấp chỉ với tên lớp và taxonomies. Tất cả đều yêu cầu truy cập vào không gian nhãn thực tế, đây là hạn chế mà MiniML nhằm khắc phục.

2.3. Phân loại văn bản Zero-shot

Phân loại zero-shot cho phép phân loại văn bản vào các danh mục chưa được huấn luyện trực tiếp. Phương pháp textual entailment chuyển đổi bài toán phân loại thành suy diễn ngôn ngữ tự nhiên, trong đó văn bản đầu vào là tiền đề và với mỗi nhãn, hệ thống xây dựng giả thuyết dạng "This example is about [label]". Mô hình NLI đánh giá mức độ tiền đề suy ra giả thuyết, và nhãn có điểm entailment cao nhất được chọn.

Dự án sử dụng ba mô hình từ HuggingFace: **bart-large-mnli** được fine-tune trên MNLI, **deberta-v3-large-all** huấn luyện trên 33 tập dữ liệu NLI, và **xlm-roberta-large-xnli** hỗ trợ đa ngôn ngữ với 100+ ngôn ngữ.

2.4. Mô hình ngôn ngữ lớn và Embedding

Gemini-flash-2.0 là mô hình 18 tỷ tham số được sử dụng trong MiniML để sinh keyphrases chủ đạo, tổng hợp nhãn đại diện từ các cụm keyphrases, và hỗ trợ đánh giá độ phủ nhãn.

Instructor-Large là mô hình embedding được fine-tune với instruction, tạo vector representations chất lượng cao cho keyphrases và hỗ trợ tính toán similarity để loại bỏ trùng lặp.

UMAP là kỹ thuật giảm chiều dựa trên topology, bảo toàn cấu trúc cục bộ và toàn cục của dữ liệu. **GMM** là mô hình xác suất giả định dữ liệu sinh từ hỗn hợp các phân phối Gaussian, linh hoạt trong việc mô hình hóa các cụm có hình dạng khác nhau. Kết hợp UMAP và GMM cho phép phân cụm hiệu quả: UMAP giảm chiều embeddings từ hàng trăm xuống vài chục chiều, sau đó GMM phân cụm trong không gian chiều thấp.

CHƯƠNG 3: PHƯƠNG PHÁP CỦA SẢN PHẨM

3.1. Hướng tiếp cận

3.1.1. Các quan sát nền tảng

Trước khi thiết kế hệ thống MiniML, tôi đã tiến hành khảo sát và phân tích dữ liệu quy mô lớn trên 5 tập benchmark để tìm hiểu đặc tính của dữ liệu phân loại đa nhãn. Qua quá trình này, hai quan sát quan trọng được phát hiện, làm nền tảng cho toàn bộ thiết kế framework.

Quy trình khảo sát:

1. Lấy mẫu ngẫu nhiên 300 văn bản từ mỗi tập dữ liệu, lặp lại 100 lần
2. Sử dụng LLM để kiểm tra xem có nhãn nào trong các nhãn thực tế (ground-truth labels) của văn bản là lớp chủ đạo hay không
3. Định nghĩa "lớp chủ đạo" là nhãn bao phủ hơn 50% nội dung văn bản
4. Tính toán tỷ lệ văn bản có lớp chủ đạo và phân tích nhãn hiếm

Quan sát 1 - Sự tồn tại phổ biến của lớp chủ đạo:

Phân tích trên năm tập dữ liệu benchmark cho thấy hơn 80% văn bản có một lớp chủ đạo. Trong bối cảnh phân loại đa nhãn, khi các nhãn không có thứ tự ưu tiên

nội tại, chúng tôi giả định mỗi nhãn đóng góp đều nhau vào nội dung văn bản. Do đó, lớp chủ đạo được xác định khi văn bản chỉ có một nhãn duy nhất.

Hầu hết các văn bản (>80% trong dataset) có một lớp chủ đạo bao phủ hơn 50% nội dung. Kết quả cụ thể trên từng tập dữ liệu:

Tập dữ liệu	# Dataset	# Label	Số lớp chủ đạo	Tỷ lệ có lớp chủ đạo
AAPD	53,840	54	44,150	82.0%
Reuters-21578	7,769	90	6,437	81.7%
RCV1-V2	643,531	103	548,289	85.2%
DBPedia-298	196,665	298	169,919	86.4%
Amazon-531	29,487	531	22,794	77.3%

Bảng 3.1: Tỷ lệ văn bản có lớp chủ đạo trên các tập dữ liệu

Giải thích kết quả: Tập Reuters-21578 có tỷ lệ cao nhất (86.4%) do chủ yếu chứa các văn bản đơn nhãn. Ngược lại, Amazon-531 có tỷ lệ thấp nhất (77.3%) do sự pha trộn giữa các nhãn chi tiết (fine-grained) và nhãn tổng quát (coarse-grained), gây khó khăn trong việc xác định nhãn chủ đạo.

Quy trình thực nghiệm:

Trong bối cảnh MLTC, mỗi tài liệu d_i được gán một tập nhãn Y_i và các nhãn trong cùng một tài liệu không có thứ tự ưu tiên nội tại. Theo các nghiên cứu tổng quan về MLTC, khi không có thông tin về mức độ quan trọng tương đối giữa các nhãn, các nhãn thường được **đối xử ngang bằng** trong các phân tích thống kê. Do đó, chúng tôi giả định rằng nếu một tài liệu có Y_i nhãn thì mỗi nhãn đóng góp một phần bằng nhau vào nội dung tài liệu. Vì vậy, **tỷ lệ tài liệu có lớp chủ đạo (Dominant Ratio)** được xác định bằng tỷ lệ các tài liệu đơn nhãn trên tổng số tài liệu trong tập dữ liệu.


$$\exists l \in Y_i \text{ s.t. } \frac{1}{|Y_i|} > 0.5$$

$$\frac{1}{|Y_i|} > 0.5 \iff |Y_i| = 1$$


$$\text{Dominant Ratio} = \frac{\#\{d_i \mid |Y_i| = 1\}}{N}$$

Quan sát 2 - Nhãn hiếm xuất hiện như lớp chủ đạo:


Nhãn hiếm được định nghĩa là các nhãn xuất hiện trong dưới 1% tập dữ liệu. Phân tích cho thấy 100% các nhãn, bao gồm cả nhãn hiếm, xuất hiện như lớp duy nhất trong ít nhất một văn bản. Điều này có ý nghĩa quan trọng: ngay cả nhãn hiếm nhất cũng có cơ hội được khám phá nếu phương pháp đúng đắn được áp dụng [9]



Hình 3.1: Tỷ lệ văn bản có lớp chủ đạo trên các tập dữ liệu



Hình 3.2: Tỷ lệ các phân phối nhãn đuôi của bộ dữ liệu AAPD



Hình 3.3: Tỷ lệ các phân phối nhãn đuôi của bộ dữ liệu RCV1-v2


3.1.2. Ý tưởng thiết kế

Dựa trên hai quan sát trên, MiniML được thiết kế với các ý tưởng cốt lõi sau:

1. Khai thác lớp chủ đạo: Chia văn bản thành các đoạn nhỏ (chunks) với kích thước phù hợp để đảm bảo mỗi đoạn chủ yếu chứa một nhãn. Kích thước max 60 tokens được chọn dựa trên phân tích mối quan hệ giữa số từ trong văn bản và số nhãn ground-truth.
2. Xây dựng không gian nhãn ban đầu: Sử dụng LLM để giúp sinh keyphrases cho mỗi chunk. Điều này giải quyết vấn đề các keyphrases khác về từ vựng nhưng giống về ngữ nghĩa.
3. Cải thiện lặp lại để khám phá nhãn hiếm: Sử dụng bộ phân loại zero-shot để xác định các đoạn văn bản thiếu lớp chủ đạo trong không gian nhãn hiện tại, từ đó khám phá thêm các nhãn hiếm.
4. Phân loại cuối cùng: Áp dụng textual entailment kết hợp cho cả chunks và keyphrases để gán nhiều nhãn cho mỗi văn bản, tận dụng thông tin ở cả hai mức độ granularity.

3.2. Cách thực hiện

3.2.1. Tiền xử lý và phân nhóm



Hình 3.4: Quy trình Phase 1 + Phase 2 của pipeline

Phase 1: Tiền xử lý văn bản

Mục tiêu của giai đoạn này là xây dựng một không gian nhãn ban đầu chất lượng cao từ tập văn bản không có nhãn

Bước 1 - Chunking

- Chia mỗi văn bản D_i trong D_{sub} thành các đoạn $\{S^1_i, S^2_i, \dots\}$ với các mốc 50 tokens như chiến lược chunking

- Mốc 50 tokens được chọn dựa trên khảo sát văn học: tỷ lệ số từ/số nhãn của dataset trung bình cho thấy 50 tokens thường chứa một nhãn
- Với chiến lược chunking tôn trọng các ranh giới giữa các header, các đoạn cách đoạn, cách dòng, dấu câu để hạn chế việc cắt ở giữa câu / giữa các đoạn

Bước 2 - Generate keyphrase

- Prompt LLM (Gemini-flash-2.0) với nội dung sinh ra các coarse label (nhãn thô, mang ý nghĩa chung, không quá đặc tả cho 1 chunk)
- LLM sinh ít nhất 3 keyphrases chủ đạo p_i cho mỗi chunk S_i
- Tập hợp tất cả keyphrases thành tập P

Phase 2: Phân loại các keyphrase

Mục tiêu của giai đoạn này là xây dựng không gian nhãn ban đầu từ tập keyphrase P thu được ở Phase 1. Do các keyphrase được sinh bởi mô hình ngôn ngữ lớn có thể khác nhau về mặt biểu đạt nhưng tương đồng về ngữ nghĩa, vì thế cần hình thành các nhãn đại diện ổn định.

Bước 1 - Embedding:


- Các keyphrase trong P được ánh xạ sang không gian vector thông qua mô hình **Instructor-Large**

Bước 2 - Phân nhóm:

- Sau khi embedding, các vector được giảm chiều bằng **UMAP** để làm nổi bật cấu trúc ngữ nghĩa tiềm ẩn.

- Trên không gian đã được giảm chiều, hệ thống sử dụng **Gaussian Mixture Model (GMM)** để gom cụm các keyphrase, trong đó mỗi cụm được giả định tương ứng với một nhãn tiềm ẩn trong dữ liệu.
- Số lượng cụm ban đầu được ước lượng với sự hỗ trợ của **BERTopic**, nhằm cân bằng giữa độ bao phủ của không gian nhãn và mức độ chi tiết của từng nhãn.

3.2.2. Tạo label space thô ban đầu



Hình 3.5: Quy trình Phase 3 + Phase 4 của pipeline

Phase 3: Tạo tên cho các nhóm keyphrase

Mục đích là sinh ra một nhãn đại diện duy nhất cho mỗi cụm keyphrase đã được hình thành ở giai đoạn trước. Nhãn này cần phản ánh nội dung chung của cụm, mang tính đặc trưng theo miền và đủ khái quát để có thể gán cho nhiều văn bản khác nhau.

Bước 1 - Chọn các keyphrase đại diện:

- Trong mỗi cụm keyphrase, hệ thống lựa chọn ba keyphrase nằm gần tâm cụm nhất. Các keyphrase này được xem là đại diện ổn định cho cụm do có khoảng cách ngữ nghĩa nhỏ nhất tới centroid.
- Từ mỗi keyphrase đại diện, hệ thống truy ngược lại các chunk văn bản gốc đã sinh ra keyphrase đó. Do các keyphrase trong cùng một cụm có nội dung tương đồng, các chunk này thường phản ánh cùng một chủ đề chính.
- Ba chunk được nối lại để tạo thành một văn bản tổng hợp, đóng vai trò cung cấp ngữ cảnh miền cho bước sinh nhãn.

Bước 2 - Sinh nhãn:

- Văn bản tổng hợp được đưa vào mô hình ngôn ngữ lớn Gemini-flash-2.0 với prompt hướng miền nhằm sinh ra một nhãn duy nhất đại diện cho toàn bộ cụm. Quá trình này được lặp lại cho tất cả các cụm, từ đó thu được tập nhãn ban đầu

Phase 4: Loại bỏ Keyphrases trùng lặp và sinh nhãn:

Mục đích là tinh lọc không gian nhãn ban đầu bằng cách loại bỏ các nhãn trùng lặp hoặc quá tương đồng về mặt ngữ nghĩa, từ đó đảm bảo không gian nhãn gọn nhẹ và nhất quán.

Bước 1 - Embedding ngữ nghĩa:

- Tất cả các nhãn trong label space từ Phase 3 được ánh xạ sang không gian embedding bằng mô hình Sentence-Transformer all-MiniLM-L6-v2. Độ tương đồng cosine giữa từng cặp nhãn được tính toán để đánh giá mức độ trùng lặp ngữ nghĩa.

Bước 2 - Đánh giá dựa trên similarity score:

- Với các cặp có similarity > 0.75 : loại bỏ nhãn đầu tiên trong cặp
- Với các cặp có similarity từ 0.5-0.75: prompt Gemini để xác định có nên loại bỏ không

"Are the following two labels semantically similar or do they represent essentially the same category?"

Label 1: "<label₁>"

Label 2: "<label₂>"

Consider whether documents assigned to one label would typically also be assigned to the other.


Answer with only "YES" or "NO".

- Với các cặp có similarity < 0.5 : ta giữ lại trong label space

Kết quả cuối cùng của Phase 4 là không gian nhãn đã được loại bỏ trùng lặp, sẵn sàng cho các bước gán nhãn và mở rộng nhãn tiếp theo.

3.2.3. Vòng lặp để mở rộng label space, tăng độ phủ của label space

Phase 5: Gán nhãn cho chunk bằng suy luận ngữ nghĩa (NLI-based Classification)



Hình 3.6: Quy trình Phase 5 của pipeline

Với không gian nhãn đã xây dựng, hệ thống sử dụng bộ phân loại zero-shot dựa trên textual entailment để gán nhãn cho văn bản. [10]

Bước 1 - Tính điểm entailment giữa keyphrase và nhãn.

- Các keyphrase được sinh ra từ mỗi chunk cũng được so sánh với không gian nhãn ở phase 4 bằng mô hình suy luận ngữ nghĩa bart-large-mnli.

- Điểm entailment giữa nhãn “**c**” và keyphrase “**k**” thể hiện độ tin cậy rằng keyphrase “**k**” entail giả thuyết

"This example is constructed for c"

- Các điểm entailment giữa nhãn và từng keyphrase được tổng hợp lại theo từng chunk bằng cách lấy giá trị lớn nhất cho mỗi nhãn, nhằm khai thác thông tin ngữ nghĩa súc tích mà keyphrase mang lại.

Bước 2 - Tính điểm entailment giữa chunk và nhãn.

- Mỗi chunk văn bản được so sánh với toàn bộ các nhãn trong không gian nhãn ở phase 4 bằng bảng cùng mô hình bước 1
- Với mỗi cặp nhãn - chunk, mô hình sinh ra một điểm entailment, phản ánh mức độ mà nội dung của chunk ủng hộ giả thuyết “đoạn văn này thuộc về nhãn đó”.

Bước 3 - Kết hợp hai nguồn điểm entailment.

- Đối với mỗi chunk, hệ thống kết hợp điểm entailment từ hai nguồn: chunk–nhãn và keyphrase–nhãn.
- Điểm tổng hợp cuối cùng được tính theo trọng số, trong đó điểm từ chunk–nhãn chiếm vai trò chính, còn điểm từ keyphrase–nhãn đóng vai trò hỗ trợ.
- Nhãn có điểm tổng hợp cao nhất được chọn làm nhãn dự đoán cho chunk, kèm theo độ tin cậy tương ứng, đây là điểm đánh giá mức độ quan trọng của nhãn so với chunk

Bước 4 - Xác định các chunk có độ tin cậy thấp.

- Sau khi hoàn tất quá trình gán nhãn, các chunk được xếp hạng theo điểm entailment cao nhất. Những chunk có điểm dự đoán cao nhất thấp hơn một ngưỡng định trước (trên máy cá nhân là 0.5) được xem là các chunk thiếu nhãn chi phối.
- Từ tập này, hệ thống lựa chọn một số lượng giới hạn các chunk có độ tin cậy thấp nhất để phục vụ cho bước mở rộng nhãn (top 200)

Bước 5 - Thu thập keyphrase cho mở rộng nhãn:

- Đối với các chunk có độ tin cậy thấp, hệ thống thu thập lại các keyphrase tương ứng của chúng thành một tập dữ liệu. Đồng thời lọc bỏ ra các keyphrase có tần suất xuất hiện chưa đủ lớn trong tập dữ liệu này (trên máy cá nhân là giới hạn cận dưới có giá trị $\max(2, (\text{tổng số chunk}) / 50)$)
- Sau đó lọc ra những keyphrase chưa xuất hiện trong không gian nhãn hiện tại làm label mới (tương tự phase 4)
- Tập keyphrase này được xem là tập ứng viên cho các nhãn hiếm và sẽ được sử dụng trong các vòng lặp mở rộng không gian nhãn tiếp theo.

Bước 6 - Quyết định lặp:

Quyết định lặp xảy ra khi

- Đạt số lần lặp tối đa (với cấu hình cho 5 dataset trên máy cá nhân max iteration là 5)
- Không có keyphrase mới được bổ sung vào

Nếu xảy ra một trong các trường hợp trên, sẽ thoát phase 5 và tiến đến phase 6


Nếu không, sẽ tiếp tục quay lại từ phase 5.

Giai đoạn Phase 5 này dựa trên giả định rằng những chunk được gán nhãn với độ tự tin thấp thường chứa các chủ đề hiếm hoặc các khái niệm chưa được mô hình hóa đầy đủ trong tập nhãn hiện có.

Tóm lại: phase 5 trả lời cho nhận định: “Nếu một khái niệm liên tục xuất hiện ở những nơi mà mô hình không biết gán nhãn gì, thì rất có thể đó là một nhãn mà chúng ta chưa biết.” [\[11\]](#)

Phase 6 : Phân loại các văn bản dựa trên tập đã được mở rộng ở phase 5

Sau khi tất cả các chunk đã được gán nhãn, hệ thống tổng hợp kết quả lên cấp độ document.



Hình 3.7: Quy trình Phase 6 của pipeline

Bước 1 - Tính điểm số của từng chunk

- Từ phase 5: Lấy lại điểm entailment (bước 3 phase 5)

Bước 2: Thu thập nhãn từ các chunk của mỗi document

Sau khi có được nhãn dự đoán cho từng chunk, hệ thống tiến hành nhóm các chunk lại theo document gốc mà chúng thuộc về.

Quá trình này sử dụng ánh xạ giữa chunk và document đã được thiết lập từ Phase 1 khi thực hiện việc chia nhỏ văn bản.

Đối với mỗi document, hệ thống thu thập toàn bộ nhãn dự đoán cùng với điểm tin cậy tương ứng từ tất cả các chunk thuộc document đó.

Bước 3: Tính điểm tổng hợp cho mỗi nhãn ở cấp document

- Để tổng hợp từ cấp độ chunk lên cấp độ document, hệ thống áp dụng phương pháp bỏ phiếu có trọng số. Cụ thể, mỗi chunk được xem như một "lá phiếu" ủng hộ cho nhãn của nó, và trọng số của lá phiếu này chính là điểm tin cậy mà chunk đó được gán nhãn. Do đó, nếu một nhãn xuất hiện nhiều lần trong các chunk của cùng một document và các lần xuất hiện đó đều có điểm tin cậy cao, thì tổng điểm của nhãn đó sẽ rất lớn.
- Ngược lại, một nhãn chỉ xuất hiện một lần hoặc xuất hiện với điểm tin cậy thấp sẽ có tổng điểm nhỏ hơn đáng kể.
- Phương pháp này giúp phản ánh cả hai yếu tố quan trọng là tần suất xuất hiện và độ tin cậy của nhãn trong toàn bộ document.

Bước 4: Áp dụng margin threshold để lọc nhãn chất lượng cao

- Một trong những bước quan trọng nhất trong việc đảm bảo chất lượng phân loại là áp dụng ngưỡng chênh lệch giữa các nhãn. Hệ thống không đơn giản chọn top-k nhãn có điểm cao nhất mà còn kiểm tra xem các nhãn này có thực sự có độ liên quan tương đương với nhau hay không.

- Cụ thể, nhãn đứng đầu luôn được chọn
- Tuy nhiên, đối với các nhãn tiếp theo, chúng chỉ được giữ lại nếu chênh lệch điểm so với nhãn đứng trước nhỏ hơn 0.15. Ngưỡng này được thiết lập dựa trên quan sát rằng khi chênh lệch lớn hơn 0.15, nhãn sau thường kém quan trọng hơn đáng kể và có thể gây nhiễu cho kết quả cuối cùng.

Nhờ cơ chế lọc này, một document có chủ đề rõ ràng có thể chỉ được gán một hoặc hai nhãn, trong khi document có nhiều chủ đề phân hóa rõ có thể được gán nhiều nhãn hơn.

3.3. Tổng kết phương pháp

Pipeline MiniML giải quyết bài toán phân loại văn bản đa nhãn thể giới mở không giám sát thông qua ba giai đoạn được thiết kế dựa trên các quan sát về đặc tính dữ liệu:

Giai đoạn	Mục tiêu	Kỹ thuật chính
1	Xây dựng không gian nhãn ban đầu	Chunking + LLM prompting + UMAP + GMM clustering
2	Phân loại dựa trên Textual Entailment	Zero-shot NLI classification + Result merging
3	Cải thiện không gian nhãn lặp lại	Low-entailment detection + Long-tail label discovery

Bảng 3.2: Tóm tắt ba giai đoạn của MiniML

Ưu điểm của MiniML:

- Không yêu cầu mô tả ngắn gọn về mục tiêu phân loại từ người dùng
- Tự động khám phá không gian nhãn phù hợp với dữ liệu
- Đặc biệt hiệu quả trong việc phát hiện nhãn hiếm

- Kết hợp linh hoạt các kỹ thuật mới: LLM, embeddings, clustering, NLI

CHƯƠNG 4: THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1. Mục tiêu thực nghiệm

Thực nghiệm được thiết kế để đánh giá toàn diện hiệu suất của MiniML qua hai tiêu chí chính:

1. **Chất lượng không gian nhãn (Label Space Quality):** Đánh giá mức độ mà không gian nhãn được sinh ra tự động bao phủ được không gian nhãn thực tế (ground-truth label space). Đây là tiêu chí quan trọng nhất vì nó đo lường trực tiếp khả năng khám phá nhãn của phương pháp.
2. **Độ chính xác phân loại (Classification Accuracy):** Đánh giá hiệu suất end-to-end của hệ thống phân loại đa nhãn zero-shot. Tiêu chí này cho thấy khả năng ứng dụng thực tế của phương pháp trong việc gán nhãn cho văn bản mới.

4.2. Quy trình thực nghiệm

4.2.1. Thông số đánh giá

a) Chỉ số Coverage (Độ phủ không gian nhãn):

Coverage là chỉ số đánh giá tự động đo lường sự căn chỉnh giữa không gian nhãn thực tế (Ground-Truth - GT) và không gian nhãn được dự đoán. Quy trình đánh giá chi tiết:

1. Tính cosine similarity giữa mỗi cặp (predicted_label, GT_label) sử dụng mô hình all-MiniLM-L6-v2 từ HuggingFace Sentence-Transformers
2. Nếu similarity > 0.75: nhãn GT được coi là "covered" (được phủ)
3. Nếu similarity $\in [0.5, 0.75]$: prompt Gemini với instruction

*"Do label pairs have similar meanings?
If Yes, please output the label
that we should delete"*
4. Nếu similarity < 0.5: không so sánh do khác biệt rõ ràng
5. Áp dụng thuật toán bipartite graph maximum matching để ghép cặp tối ưu

Công thức Coverage:

$$\text{Coverage} = \frac{1}{N} \sum_{g \in C^{GT}} \mathbb{I}(g \in C^{pred})$$

Trong đó:

- + N là tổng số nhãn trong GT label set
- + C^{GT} và C^{pred} là tập nhãn ground-truth và predicted
- + I là indicator function trả về 1 nếu nhãn GT được "covered"
- + G là thuật toán bipartite graph maximum match.

b) Chỉ số Precision@k (P@k):

P@k là chỉ số rank-based phổ biến trong multi-label classification với không gian nhãn lớn. P@k đo phần trăm nhãn đúng trong top-k nhãn có điểm cao nhất.

Công thức:

$$P@k = \frac{1}{N} \sum_{i=1}^N \frac{|C_i^{r_k} \cap L_i|}{\min(k, |L_i|)}$$

Trong đó:

- + L_i và C_i là các nhãn thực tế và dự đoán cho văn bản D_i
- + $|L_i|$ là số nhãn thực tế cho D_i
- + r_k là nhãn dự đoán thứ k cao nhất.

Nhãn ground-truth được định nghĩa "covered" theo cùng coverage metric.

4.2.2. Chi tiết thực nghiệm

a) Tập dữ liệu:

Thực nghiệm được thực hiện trên 5 tập dữ liệu benchmark đa dạng về lĩnh vực và quy mô:

Tập dữ liệu	# Train	# Label	Mô tả chi tiết
AAPD	53,840	54	Bài báo khoa học máy tính với các chủ đề nghiên cứu
Reuters-21578	7,769	90	Tin tức tài chính từ Reuters năm 1987
RCV1-V2	643,531	103	Tin tức phân loại từ Reuters Ltd
DBPedia-298	196,665	298	Wikipedia với danh mục bài viết
Amazon-531	29,487	531	Đánh giá sản phẩm với tags sản phẩm

Bảng 4.1: Thống kê chi tiết các tập dữ liệu benchmark

Đặc điểm các tập dữ liệu:

- AAPD (Arxiv Academic Paper Dataset): Tập dữ liệu trung bình về kích thước với 54 nhãn, phù hợp để đánh giá khả năng xử lý văn bản học thuật

- Reuters-21578: Tập dữ liệu kinh điển trong nghiên cứu text classification, chứa nhiều nhãn viết tắt (abbreviations)
- RCV1-V2: Tập dữ liệu lớn nhất với hơn 800,000 văn bản, thách thức về khả năng mở rộng
- DBPedia-298: Không gian nhãn lớn (298 lớp), thách thức về khám phá nhãn đa dạng
- Amazon-531: Không gian nhãn lớn nhất (531 lớp) với nhiều nhãn fine-grained, thách thức về nhãn hiếm

b) Các phương pháp so sánh:

1. Nhóm 1 - Topic Modeling:

- a. LDA: Phương pháp cổ điển dựa trên xác suất sinh
- b. NMF: Phân tích ma trận không âm
- c. Top2Vec: Embedding-based với Word2Vec mở rộng
- d. BERTopic: BERT embeddings + HDBSCAN clustering
- e. TopicGPT: LLM-based topic generation

2. Nhóm 2 - Keyword Extraction:

- a. PKE: Keyphrase extraction dựa trên confidence scores
- b. TextRank: Graph-based ranking với cơ chế voting
- c. TF-IDF: Trọng số dựa trên tần suất trong văn bản và nghịch đảo tần suất trong corpus

c) Chi tiết triển khai:

Thành phần	Chi tiết
LLM	Gemini-flash-2.0
Hardware	T4 GPU - GoogleColab
Memory sử dụng	< 15GB GPU memory
Chunk size	Lấy 50 token làm mốc
Embedding model	Instructor-Large
Similarity model	all-MiniLM-L6-v2
Similarity threshold	0.75 (high), 0.5-0.75 (Gemini-flash-2.0 verify)
Thời gian LLM prompting (batch)	~1 giờ/dataset (~8,000 chunks trung bình)
Thời gian mỗi iteration	~30p

Bảng 4.2: Chi tiết triển khai hệ thống

4.2.3. Kết quả độ phủ không gian nhãn

So sánh Coverage giữa MiniML và các baseline:


Phương pháp	AAPD	Reuters	RCV1-V2	DBPedia	Amazon
PKE	14.29	14.44	25.24	25.84	15.44
TextRank	18.37	11.11	11.65	14.77	12.43
TF-IDF	14.29	15.56	8.74	26.51	12.24
LDA	30.61	17.77	12.74	11.40	13.18
NMF	28.57	17.77	12.74	28.18	15.06
Top2Vec	32.65	20.00	28.43	30.87	14.50
BERTopic	20.41	20.00	10.68	33.22	16.76
TopicGPT	41.66	25.55	23.30	41.61	32.20
MiniML	67.36	32.53	51.12	57.23	34.04

Bảng 4.3: So sánh độ phủ không gian nhãn (%) - Giá trị cao nhất được in đậm

Phân tích kết quả:

1. Hiệu suất tốt: MiniML cao với tất cả baseline trên mọi tập dữ liệu. Trên AAPD, RCV1-V2, và DBPedia-298, phương pháp đạt >50% coverage
2. Khả năng khám phá nhãn hiếm: MiniML đặc biệt xuất sắc trong việc sinh ra các nhãn hiếm - thách thức lớn của các baseline. Quy trình cải thiện lặp lại cho phép phát hiện các nhãn hiếm này.
3. Reuters-21578: Coverage thấp hơn (32.53) do:
 - a. (1) tỷ lệ cao nhãn hiếm
 - b. (2) nhãn ground-truth sử dụng viết tắt ("acq" thay vì "acquisitions") dẫn đến similarity score thấp hơn thực tế.
4. Phân tích Amazon-531: Coverage 34.04% do không gian nhãn ban đầu chỉ bằng 1/3 ground-truth. Sau improvement stage, predicted label space vẫn < 50% ground-truth space.
5. Kiểm tra với LLM khác: Thử nghiệm với Qwen-3-1.7B (chưa fine tuning) trên AAPD và RCV1-V2 cho kết quả tương tự: 65.51% và 49.19%, xác nhận tính robust của phương pháp với các LLM khác nhau.

4.2.4. Kết quả phân loại Zero-shot



Hình 4.1: So sánh độ chính xác phân loại với 3 mô hình entailment

Classifier	Method	AAPD P@1	P@3	Reuters P@1	P@3	RCV1 P@1	P@3	DBP P@1	P@3	Amz P@1	P@3
bart-large-mnli	Vanilla	0.203	0.259	0.094	0.255	0.422	0.376	0.642	0.366	0.508	0.393
	MiniML	0.332	0.374	0.163	0.362	0.453	0.381	0.689	0.400	0.662	0.461
deberta-v3-large	Vanilla	0.386	0.370	0.129	0.394	0.466	0.415	0.637	0.382	0.597	0.407
	MiniML	0.357	0.401	0.132	0.415	0.482	0.431	0.635	0.395	0.620	0.465
xlm-roberta-xnli	Vanilla	0.186	0.233	0.145	0.348	0.327	0.305	0.650	0.367	0.506	0.386
	MiniML	0.271	0.347	0.204	0.397	0.404	0.338	0.661	0.391	0.584	0.455

Bảng 4.4: So sánh độ chính xác phân loại Zero-shot Multi-label

Phân tích kết quả phân loại:

- MiniML đạt P@3 cao hơn baseline trên tất cả datasets với mọi classifier
- Quy trình chunk-splitting tăng khả năng tìm các nhãn ít chủ đạo hơn - chúng có thể trở thành chủ đạo trong chunks nhỏ hơn
- Việc kết hợp kết quả từ cả keyphrases và chunks cải thiện đáng kể multi-label performance

4.2.5. Cải thiện Coverage qua các vòng lặp

Tập dữ liệu	Ban đầu (%)	Sau cải thiện (%)	Δ
AAPD	41.60	67.36	+25.76%
Reuters-21578	25.44	32.53	+7.09 %
RCV1-V2	45.71	51.12	+5.41 %
DBPedia-298	50.70	57.23	+6.53 %
Amazon-531	29.35	34.04	+4.69 %

Bảng 4.5: Cải thiện Coverage qua quy trình cải thiện lặp lại


Phân tích cải thiện:

- AAPD có cải thiện lớn nhất (+25.76%) do không gian nhãn nhỏ hơn, dễ mở rộng hơn
- Reuters và Amazon có initial coverage thấp, nhiều nhãn matching chưa được bao gồm ban đầu, tiềm năng cải thiện cao
- DBPedia có cải thiện vừa phải (+6.53%) do thách thức mở rộng không gian nhãn lớn (298 classes)

4.2.6. Vấn đề với Amazon-531

Amazon-531 là tập dữ liệu thách thức nhất với 531 classes. Bằng việc tăng số iterations cải thiện coverage đáng kể:

- So với iteration là 5 (34.04%) thì nếu tăng iteration lên 25 thì độ phủ tăng hơn đáng kể (48.03%); đổi lại, thời gian và chi phí cũng tăng theo (Từ 45p -> 5h chỉ cho pha iteration)
- Điều này xác nhận quy trình cải thiện lặp lại hiệu quả, đặc biệt với label space lớn, đổi lại thời gian chờ bị đội lên rất cao



Hình 4.2: Cải thiện Coverage qua việc tăng số lần lặp lại trên Amazon-531

4.2.7. Ảnh hưởng của kích thước chunk

Khảo sát với mốc chunk size 250 tokens - trung bình 1 đoạn (thay vì 50 - trung bình 3 câu):

- AAPD: 53.26% (so với 67.36% với chunk 50)
- RCV1-V2: 48.13% (so với 51.12% với chunk 50)

Kết luận: Đặt mốc chunk-size 50 tokens tối ưu hơn, đảm bảo mỗi chunk chứa chủ yếu một label, cải thiện chất lượng keyphrases và label space.

4.3. Kết luận và Hướng phát triển

4.3.1. Kết luận

Pipeline đã giải quyết thành công bài toán phân loại văn bản đa nhãn không giám sát thông qua pipeline MiniML. Các kết quả thực nghiệm trên 5 tập dữ liệu benchmark cho thấy:

- MiniML cao hơn so với tất cả các phương pháp baseline (topic modeling và keyword extraction) về độ phủ không gian nhãn với margin đáng kể
- Quy trình cải thiện lặp lại hiệu quả trong việc khám phá các nhãn hiếm - thách thức lớn nhất trong MLTC
- Độ chính xác phân loại zero-shot ($P@3$) cao hơn các mô hình top-ranking trên HuggingFace
- Phương pháp robust với các LLM khác nhau (Gemini và Qwen)

4.3.2. Hạn chế

Mặc dù đạt được kết quả tốt, MiniML vẫn có một số hạn chế:

- Hiệu quả có thể bị giới hạn với các nhãn hiếm cực độ (xuất hiện nhỏ hơn 0.0001% văn bản)
- Đối với các tập dữ liệu với không gian nhãn rất lớn (> 1000 nhãn), cần subset lớn hơn đáng kể, tăng chi phí tính toán
- Keyphrase quality phụ thuộc vào LLM, có thể biến động giữa các lần chạy

- Coverage evaluation sử dụng Google models có thể ảnh hưởng đến kết quả sau mỗi lần thử

4.3.3. Hướng phát triển

Các hướng nghiên cứu tiếp theo bao gồm:

- Phát triển các phương pháp cải tiến để nắm bắt nhiều nhãn hiếm hơn, đặc biệt cho các nhãn cực hiếm (xuất hiện $< 0.0001\%$ văn bản)
- Mở rộng để xử lý các tập dữ liệu với không gian nhãn lớn hơn đáng kể (> 1000 classes)
- Nghiên cứu các kỹ thuật để giảm chi phí tính toán LLM trong khi duy trì chất lượng

TÀI LIỆU THAM KHẢO

- [1] Zihan Wang, Dheeraj Mekala, and Jingbo Shang. 2020b. X-class: *Text classification with extremely weak supervision*. *arXiv:2010.12794*.
- [2] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altschmidt, Sam Altman, Shyamal Anadkat, et al. 2023. *Gpt-4 technical report*. *arXiv:2303.08774*.
- [3] Yuanhao Xiong, Wei-Cheng Chang, Cho-Jui Hsieh, Hsiang-Fu Yu, and Inderjit Dhillon. 2021. *Extreme zero-shot learning for extreme text classification*. *arXiv:2112.08652*.
- [4] David M Blei, Andrew Y Ng, and Michael I Jordan. 2003. Latent dirichlet allocation. *Journal of machine Learning research*, 3(Jan):993–1022.
- [5] Cédric Févotte and Jérôme Idier. 2011. Algorithms for nonnegative matrix factorization with the β - divergence. *Neural computation*, 23(9):2421–2456.
- [6] Dimo Angelov. 2020. Top2vec: Distributed representations of topics. *arXiv:2008.09470*.
- [7] Maarten Grootendorst. 2022. Bertopic: Neural topic modeling with a class-based tf-idf procedure. *arXiv:2203.05794*.
- [8] Chau Minh Pham, Alexander Hoyle, Simeng Sun, and Mohit Iyyer. 2023. Topicgpt: A prompt- based topic modeling framework. *arXiv:2311.01449*.
- [9] Dasgupta, A., Lamba, P., Kushwaha, A., Ravish, K., Katyan, S., Das, S., & Kumar, P. (2023). *Review of Extreme Multi-label Classification*. *arXiv:2302.05971*.
- [10] Marc Pàmies, Joan Llop, Francesco Multari, Nico-lau Duran-Silva, César Parra-Rojas, Aitor González- Agirre, Francesco Alessandro Massucci, and Marta

Villegas. 2023. A weakly supervised textual entailment approach to zero-shot text classification. *In Proceedings of the 17th Conference of the European*

Chapter of the Association for Computational Linguistics, pages 286–296.

[11] Yuwei Zhang, Haode Zhang, Li-Ming Zhan, Xiao-Ming Wu, and Albert Lam. 2022. *New intent discovery with pre-training and contrastive learning*. arXiv:2205.12914.



Ý kiến đánh giá:

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Điểm số: Điểm chữ:

Hà Nội, ngày tháng năm 2025
Giảng viên đánh giá
(Ký, ghi rõ họ tên)